2026 여름 산학협력 실습중심 딥러닝 부트캠프 경진대회

From Visual Recognition to Reasoning Segmentation

Team 1 신용산날라리

2026-08-14 서주영 | 김동주 | 김신웅 | 김이영

Introduce

팀 소개 | 신용산 날라리

서주영
- 성균관대 컴퓨터교육과
- 골목대장



김신웅
- 서울시립대 경제학부&인공지능
- 어~형이야

김이영
- 서울과기대 인공지능응용학과
- 여기서제일영크크

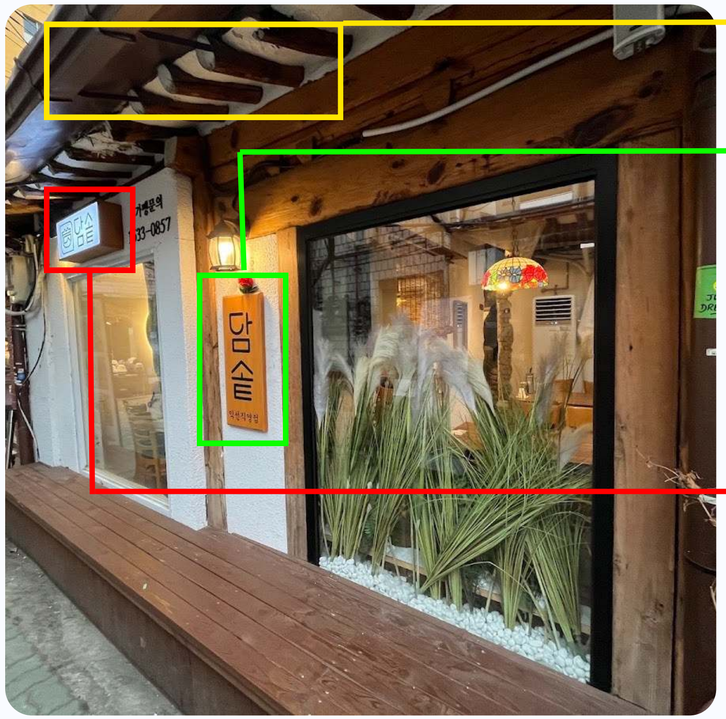
김동주
- 경북대 컴퓨터학부
- 대구불주먹

Task 1

Visual Question Answering

Task 1 Overview

example



Store Image VQA







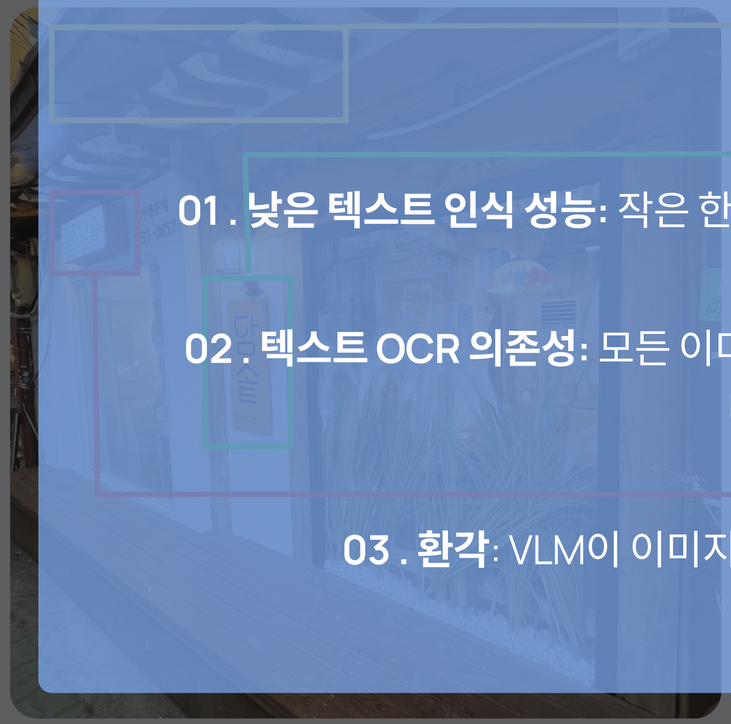
A. 한식 B. 양식 C. 일식 D. 중식 E. 카페 F. 베이커리 G. 주점 H. 동남아

→ A (한식)

Task 1 Overview

example

Store Image VQA



Challenge

01 . 낮은 텍스트 인식 성능: 작은 한글 간판·메뉴판의 글자를 충분히 읽지 못해 업종 구분 성능 저하

02 . 텍스트 OCR 의존성: 모든 이미지에 동일한 추론을 적용하면 모호한 샘플을 구분하기 어려움
다중 추론 간 불일치 활용 필요

03 . 환각: VLM이 이미지에 없는 텍스트를 상상하여 잘못 판단할 위험성 존재



A. 한식 B. 양식 C. 일식 D. 중식 E. 카페 F. 베이커리 G. 주점 H. 동남아
→ A (한식)

Our Methodology

Multimodal Inference Strategies

장면·텍스트 보존형 시각 처리

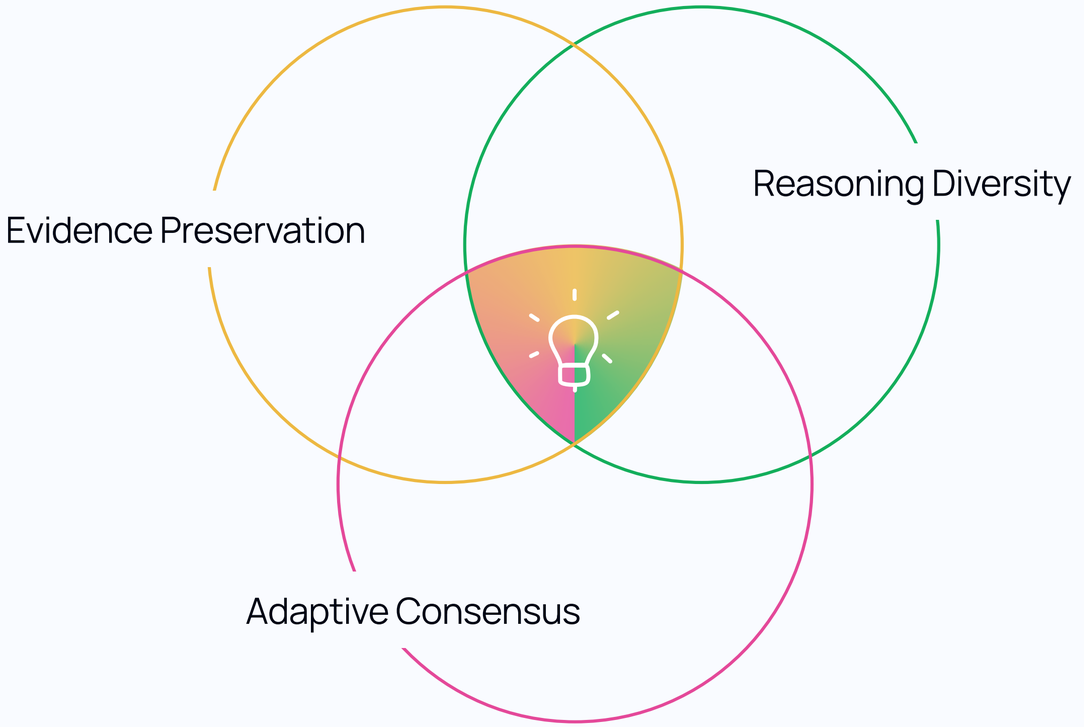
멀티스케일 리사이즈를 통해 간판·메뉴판처럼 작지만
결정적인 텍스트 단서를 최대한 보존합니다.

다중 경로 추론

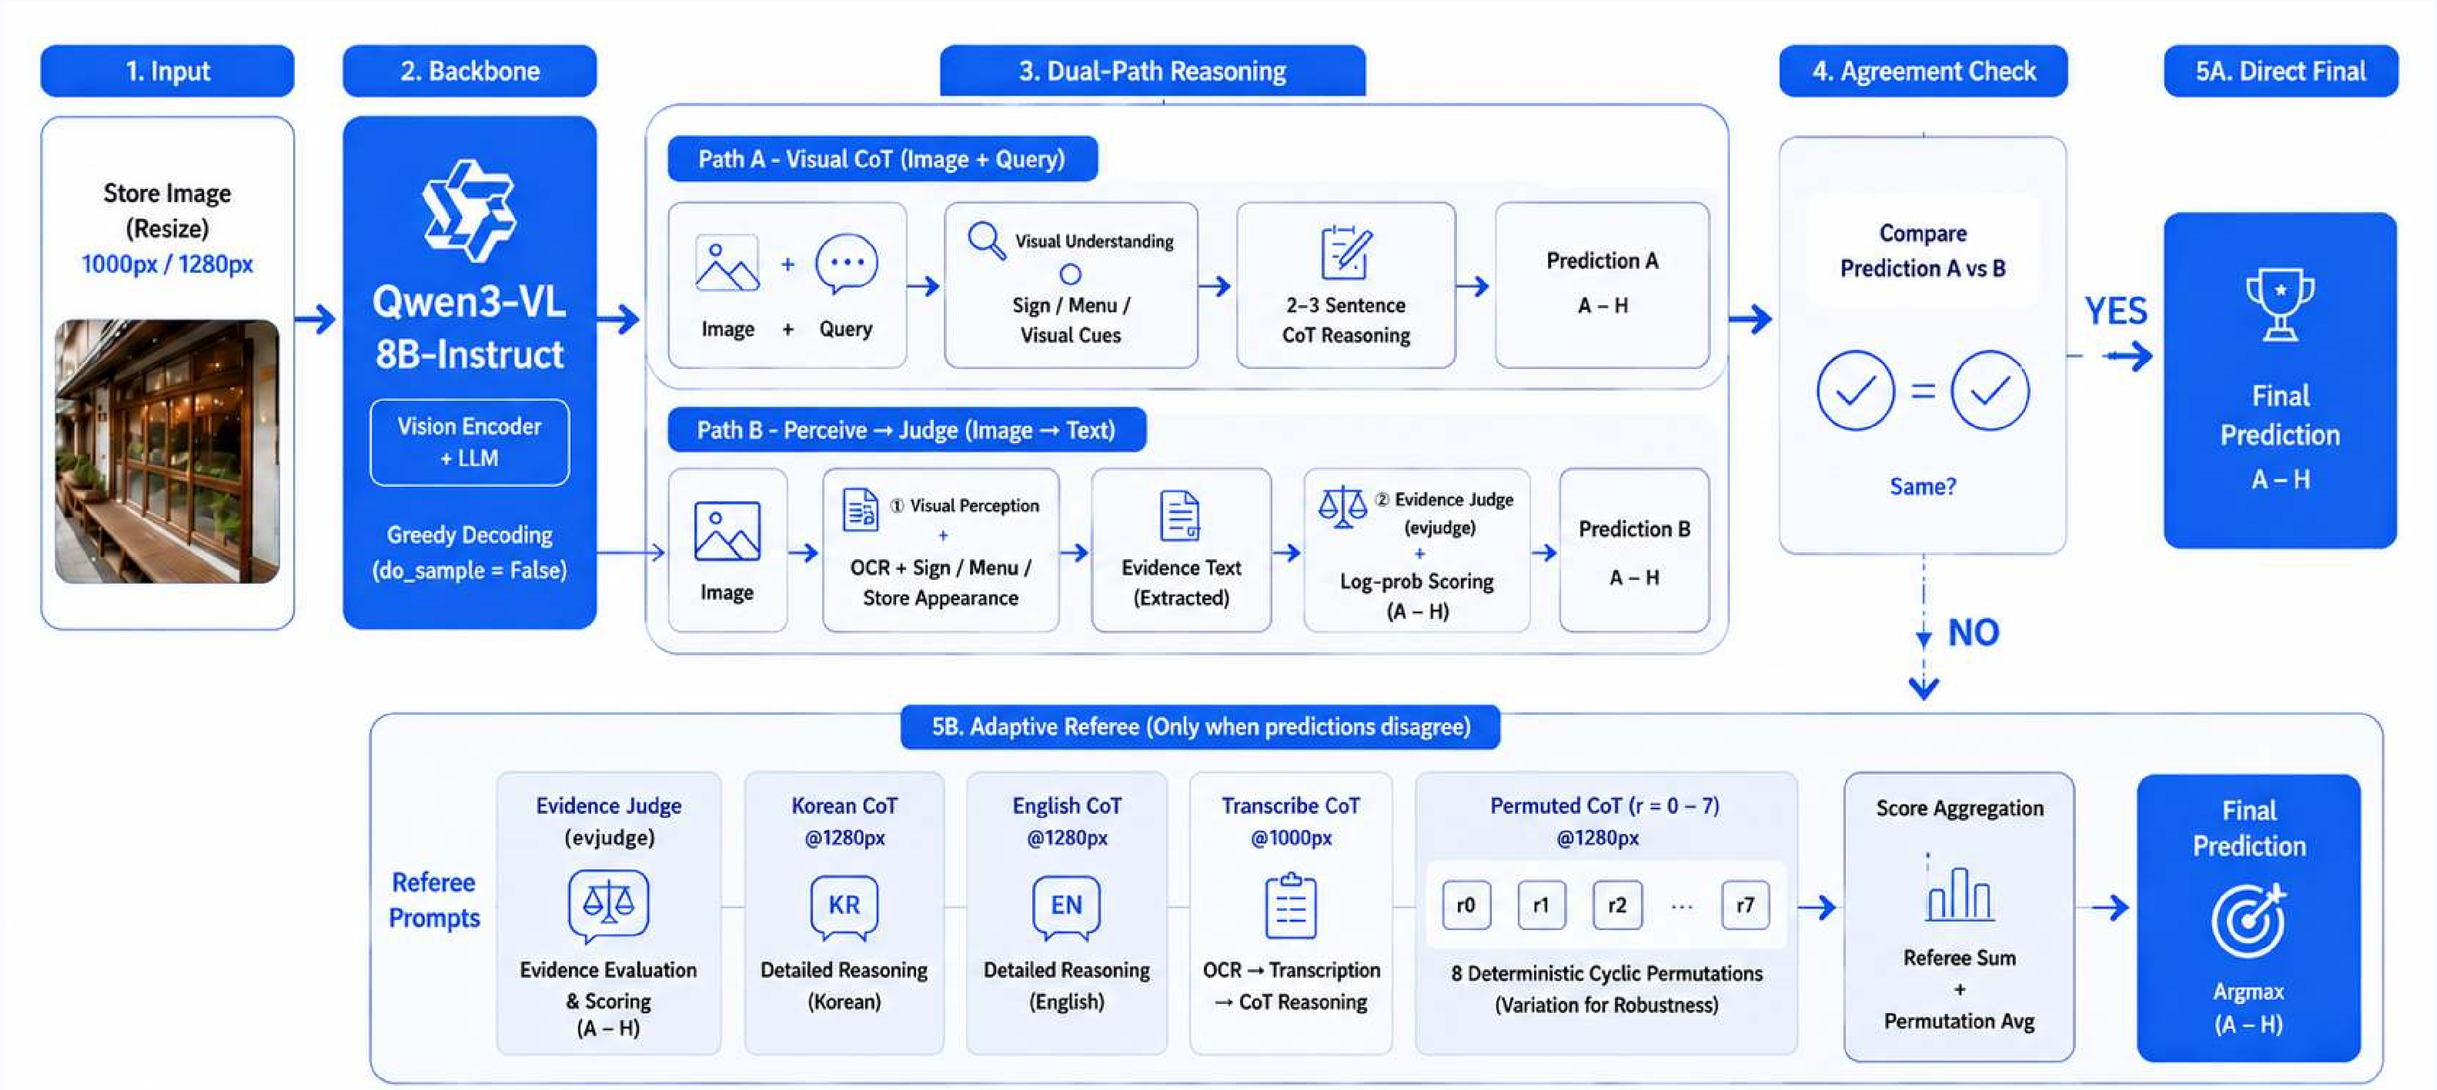
한국어/영어 프롬프트, Visual CoT, 전사 후 판단, 보기 순환 등
서로 다른 추론 경로를 구성해 샘플링 없이도 다양한 판단 관점을 확보

합의 기반 적응형 앙상블

독립적인 추론 경로가 같은 답에 도달하면 바로 채택하고, 불일치하는
어려운 샘플만 추가 앙상블로 넘겨 정확도와 효율을 동시에 확보



Pipeline


1. Input
Store Image
(Resize)
1000px / 1280px
2. Backbone
Qwen3-VL
8B-Instruct
Vision Encoder
+ LLM
Greedy Decoding
(do_sample = False)
3. Dual-Path Reasoning
Path A - Visual CoT (Image + Query)
Image + Query
Visual Understanding
Sign / Menu /
Visual Cues
2–3 Sentence
CoT Reasoning
Prediction A
A – H
Path B - Perceive → Judge (Image → Text)
Image
① Visual Perception
+
OCR + Sign / Menu /
Store Appearance
Evidence Text
(Extracted)
② Evidence Judge
(evjudge)
+
Log-prob Scoring
(A – H)
Prediction B
A – H
4. Agreement Check
Compare
Prediction A vs B
Same?
YES
5A. Direct Final
Final
Prediction
A – H
NO
5B. Adaptive Referee (Only when predictions disagree)
Referee
Prompts
Evidence Judge
(evjudge)
Evidence Evaluation
& Scoring
(A – H)
Korean CoT
@1280px
KR
Detailed Reasoning
(Korean)
English CoT
@1280px
EN
Detailed Reasoning
(English)
Transcribe CoT
@1000px
OCR → Transcription
→ CoT Reasoning
Permuted CoT (r = 0 – 7)
@1280px
r0
r1
r2
…
r7
8 Deterministic Cyclic Permutations
(Variation for Robustness)
Score Aggregation
Referee Sum
+
Permutation Avg
Final
Prediction
Argmax
(A – H)

Pipeline | Backbone



CLIP 사용 시각적으로 확인해보았을 때 성능 좋지 않음

Qwen3-VL 사용

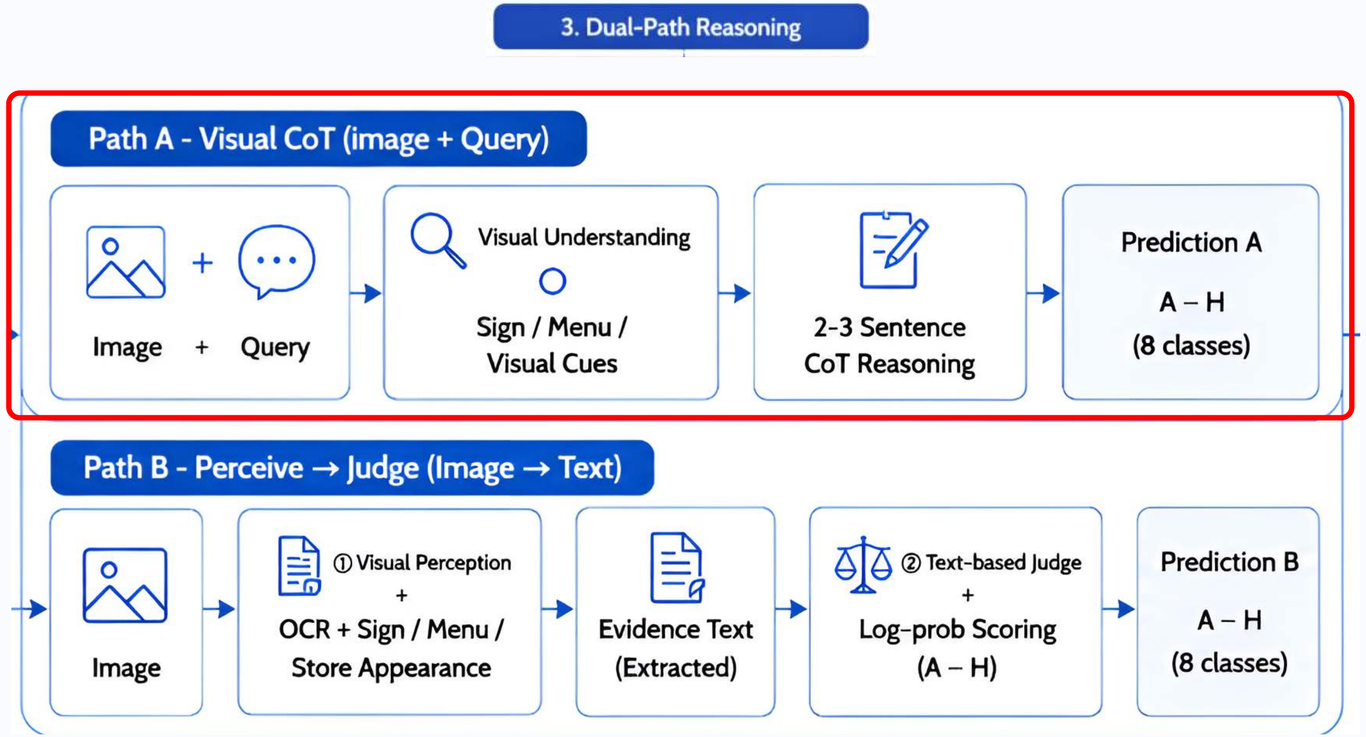
한국어 OCR & 시각 이해력

Qwen3-VL 시리즈는 다국어 간판, 미세문자, 야간/기울어진 글자 전사 능력 뛰어남

고해상도 지원 & 24GB GPU 최적화

가변 해상도(Native Dynamic Resolution) 지원 → 원본 간판의 가로세로비 유지, 고화질

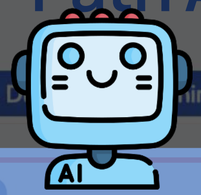
Pipeline | Dual-Path Reasoning - Path A



한국어 CoT

P3 = (QUERY + "\n\n먼저 이미지에서 보이는 간판·메뉴판 등의 글자와 시각적 단서를 "
"2~3문장으로 서술한 뒤, 마지막 줄에 반드시 '정답: X' 형식으로 A~H 중 한 글자를 출력하시오.")

Pipeline | Dual-Path Reasoning - Path A



모델에게 “A~H 중 하나 골라”라고 지시하는 것이 아니라,

01. 간판 글자읽기 → 02.메뉴 글자 읽기 → 03.시각적 단서 설명 →04.최종 분류

를 한번에 생성

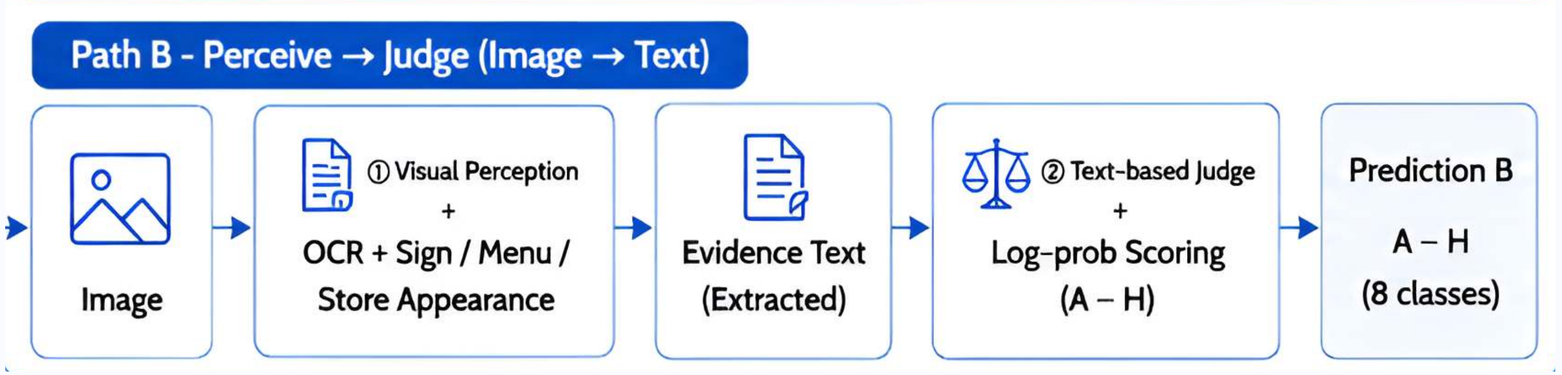
$$p(y, e|x) = p(e|x)p(y|e, x)$$

중간 evidence e 를 자연어로 먼저 생성하도록 유도

한국어 CoT

P3 = (QUERY + "\n\n먼저 이미지에서 보이는 간판·메뉴판 등의 글자와 시각적 단서를 "
"2~3문장으로 서술한 뒤, 마지막 줄에 반드시 '정답: X' 형식으로 A~H 중 한 글자를 출력하시오.")

Pipeline | Dual-Path Reasoning - Path B



독립적인 효과 업종 가설 없이 시각 증거를 먼저 추출 → 초기 판단 편향 완화 + Path A와 상이한 오류 패턴 확보

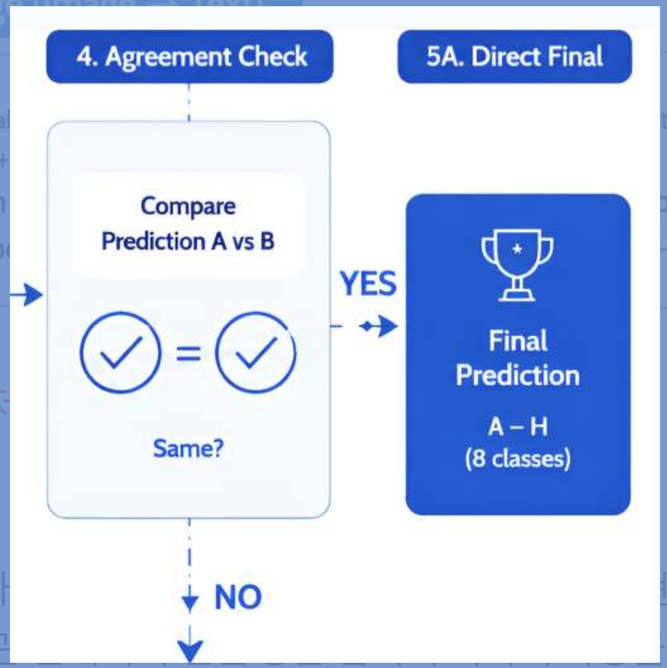
정리 CoT

PERCEIVE = ("이 이미지는 어떤 매장의 사진입니다. 다음 두 가지를 정리하시오.\n" "1) 간판·현수막·메뉴판·창문 등에 보이는 모든 글자(한국어/한자/영어)를 보이는 그대로 전사\n" "2) 매장의 외관·인테리어·진열 상품·집기의 시각적 특징을 2~3문장으로 서술\n" "형식:\n글자: ...\n특징: ...")

판단 CoT

JUDGE = ("다음은 어떤 매장 사진에서 추출한 정보입니다.\n\n{evidence}\n\n" "위 정보만을 근거로 아래 질문에 답하시오.
\n\n" + QUERY + "\n\n답은 반드시 A~H 중 알파벳 한 글자만 출력하시오.")

Pipeline | Dual-Path Reasoning - Path B



두 응답이 일치하면 Path A의 응답으로 결정, 하지만 불일치라면?

독립적인 효과 업종 가설 없이 시각 증거를 먼저 … 상이한 오류 패턴 확보

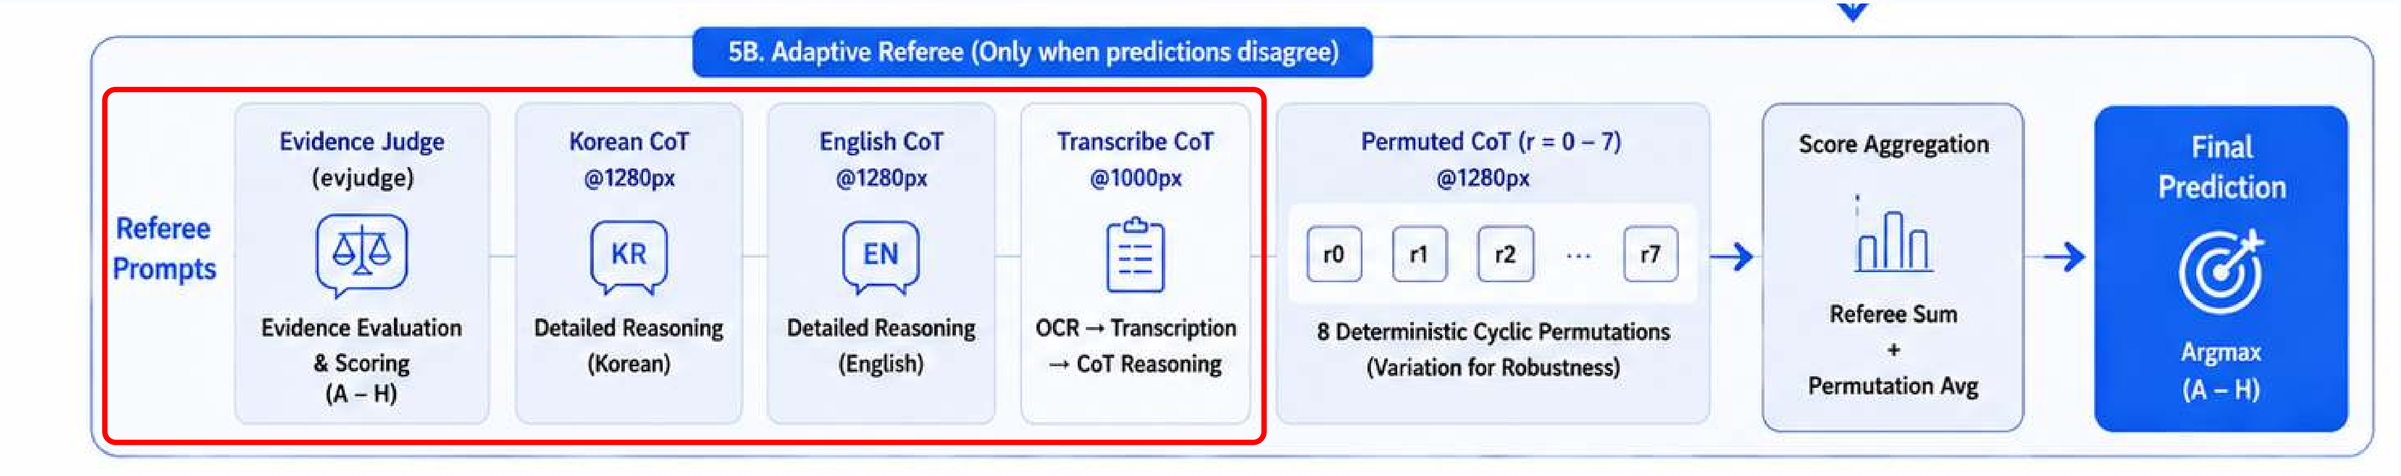
정리 CoT

PERCEIVE = ("이 이미지는 어떤 매장의 사진입니다 … 현수막·메뉴판·창문 등에 보이는 모든 글자(한국어/한자/영어)를 보이는 그대로 전사\n" "2) 매장의 외관 … 2~3문장으로 서술\n" "형식:\n글자: …\n특징: …")

판단 CoT

JUDGE = ("다음은 어떤 매장 사진에서 추출한 정보입니다.\n\n{evidence}\n\n" "위 정보만을 근거로 아래 질문에 답하시오.\n\n" + QUERY + "\n\n답은 반드시 A~H 중 알파벳 한 글자만 출력하시오.")

Pipeline | Referee



Trigger 두 독립 경로가 불일치한 어려운 샘플에만 Referee 실행, 경로간 합의를 정답 신뢰도의 대리지표로 사용

Evidence Judge (path B)

이미지 없이 추출된 시각 증거만으로 독립 판단

Korean CoT (P3) @1280px

고해상도 입력으로 작은 간판·메뉴 정보 보강

English CoT (P4) @1280px

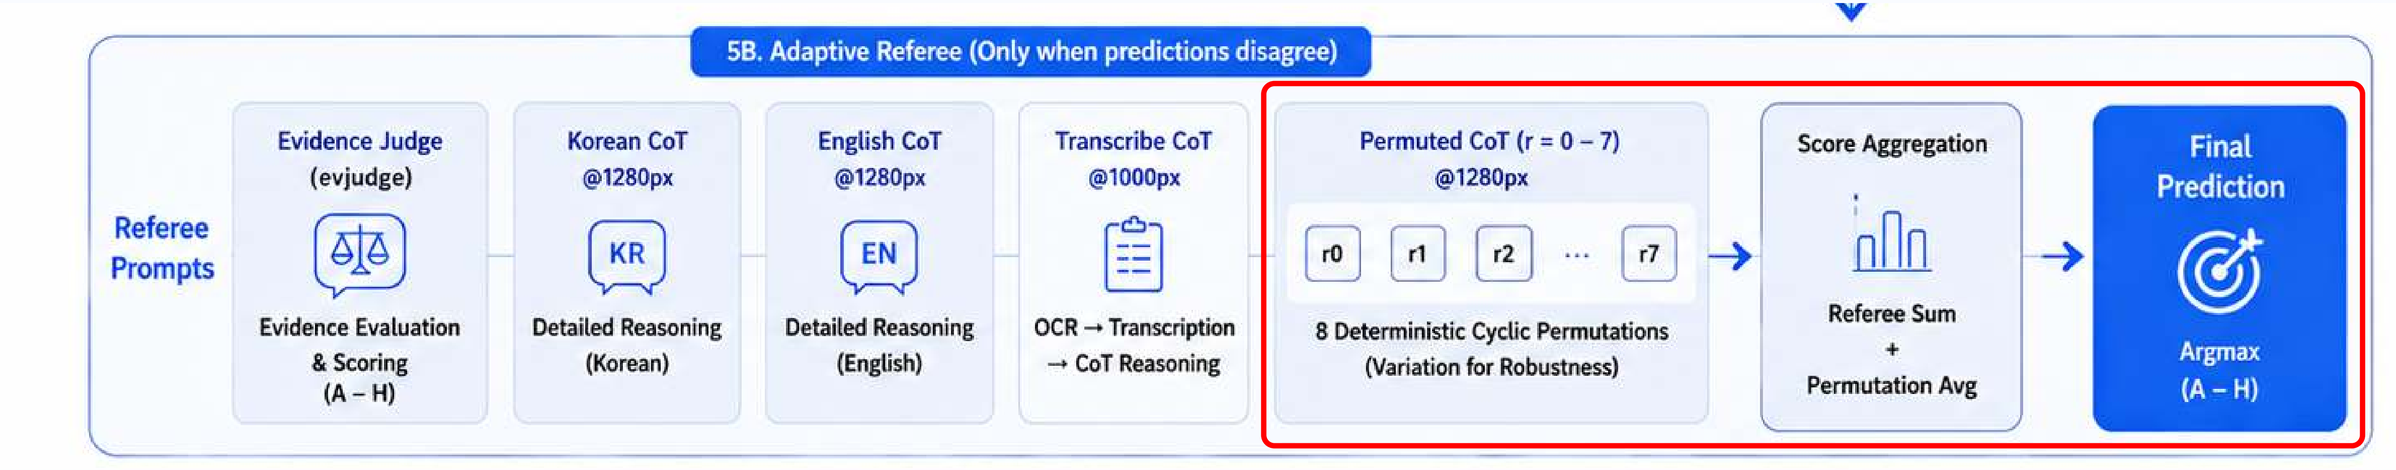
언어 프레이밍을 변경하여 추론 다양성 확보

Transcribe CoT (P6)

문자 정보를 먼저 전사한 뒤 업종 판단

Wang et al., “Self-Consistency Improves Chain of Thought Reasoning in Language Models” (ICLR 2023, arXiv:2203.11171)

Pipeline | Referee



최종 예측 서로 다른 추론 경로의 점수를 Cyclic Permutation 활용하여 계산 후, 평균하여 최종 클래스 결정

※ Cyclic Permutation: 8개 선택지를 한 칸씩 순환하여 특정 답변 위치에 대한 편향 완화 ex) A-B-C-... → B-C-D-... → ...

LLM의 선택지 위치 편향 (Option-Order Bias)

동일한 내용이라도 선택지의 배치 순서에 따라 응답 확률이 달라질 수 있음

Pezeshkpour & Hruschka, "Large Language Models Sensitivity to The Order of Options in Multiple-Choice Questions," Findings of NAACL 2024

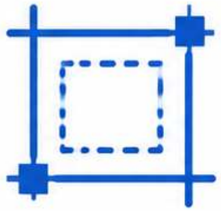
Trial and Error



1 Language Variation

단순 언어 변경만으로
일관된 성능 향상 X

→ 다양성 신호로 활용



2 Aggressive Crop

텍스트 확대 ↔
주변 문맥 손실

→ Full-image Upscaling 선택



3 Pairwise Tournament

높은 단독 정확도에도
최종 성능 향상 X

→ Error Diversity가 더 중요



4 Verify / Debate

같은 모델의 재검증은
같은 맹점 공유

→ Independent Reasoning Path 필요

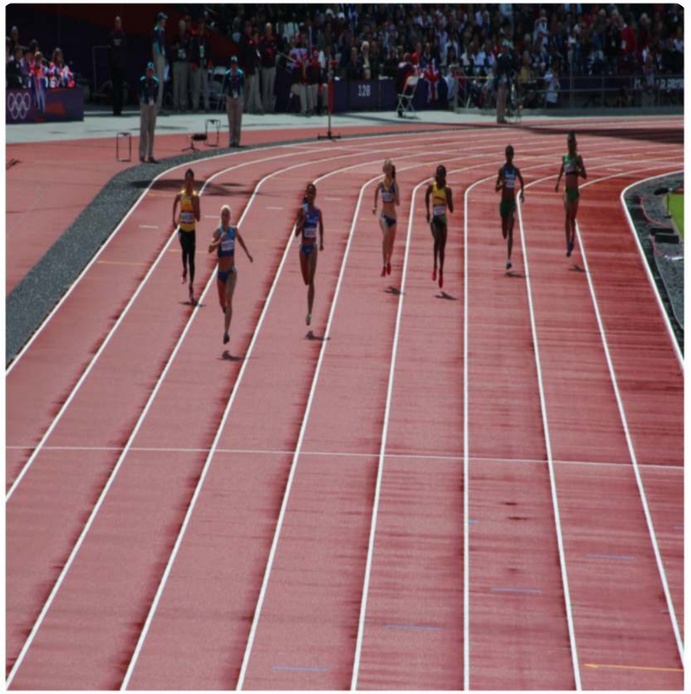
Trial & Error의 결론: 더 많은 추론보다, 서로 다른 오류를 만드는 추론이 중요

Task 2

Reasoning Segmentation

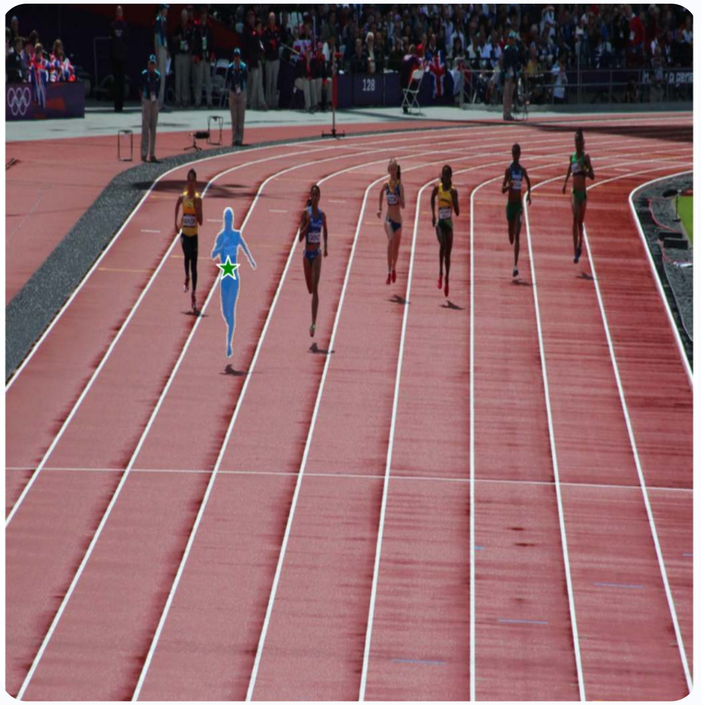
Task 2 Overview

Before



The person who is in the lead right now.

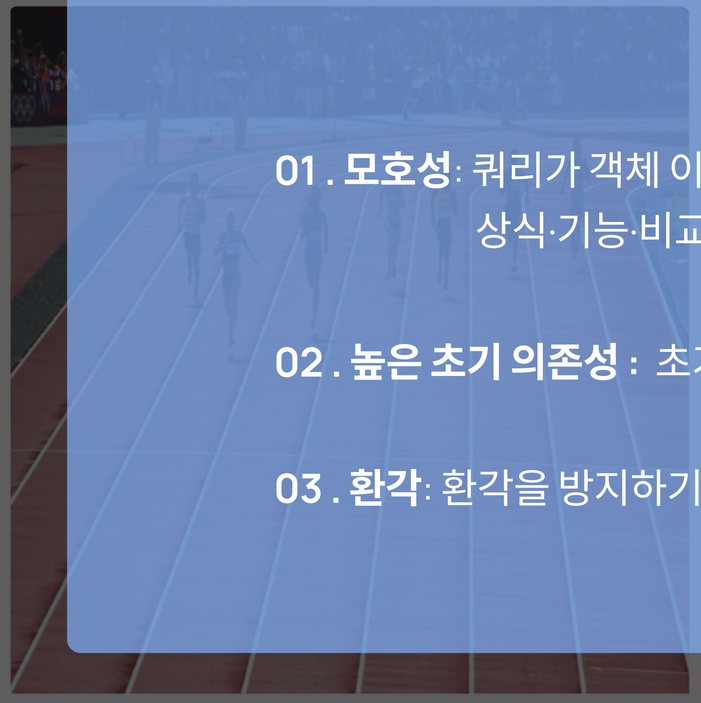
After



The person who is in the lead right now.

Task 2 Overview

Before



The person who is in the lead right now.

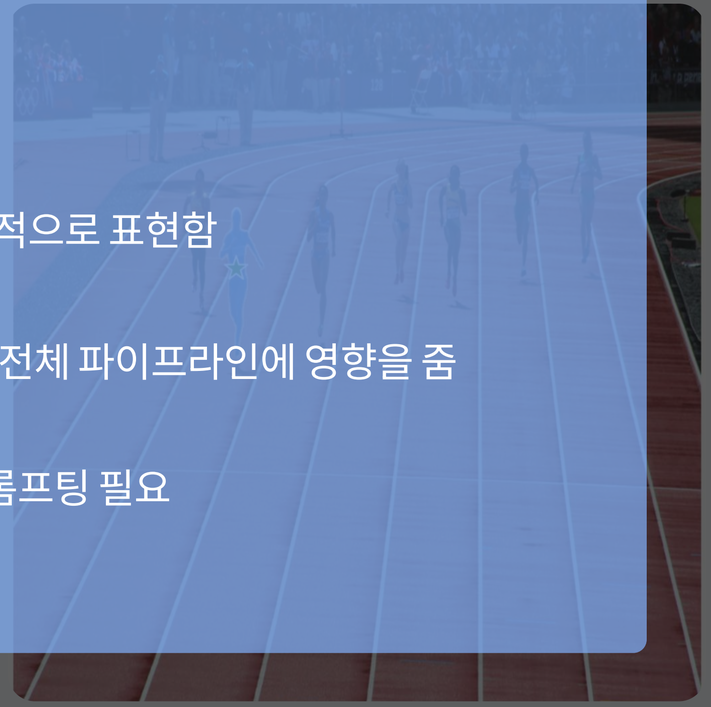
Challenge

01 . 모호성: 쿼리가 객체 이름을 직접 제시하지 않고,
상식·기능·비교·계산 등을 요구하며, 대상을 간접적으로 표현함

02 . 높은 초기 의존성 : 초기에 잘못된 추론을 시작하면 이후 전체 파이프라인에 영향을 줌

03 . 환각: 환각을 방지하기 위한 여러 스텝의 reasoning, 프롬프팅 필요

After



The person who is in the lead right now.

Task 2 Overview

영감의 근원

Before

After

StAR: Segment Anything Reasoner

Seokju Yun[1,2], Dongheon Lee[2], Noori Bae[2], Jaesung Jun[2], Chanseul Cho[2], and Youngmin Ro[2†]

[1] KAIST AI
[2] University of Seoul

교수님.....?
조교님..?



① 답변 포맷 — StAR가 설계공간 탐구로 확정한 bbox+point JSON → SAM 프롬프트 출력 규격을 채택
→ 우리 로직: Qwen3-VL이 좌표 JSON 생성 → SAM2.1이 픽셀 마스크화 (파이프라인 골격)

② 병렬 Test-Time Scaling — 여러 추론 경로를 만들어 집계(MV)하면 성능 한계를 넘는다
→ 우리 로직: 샘플링 금지 규정에 맞춰 재구현
멀티스케일·프롬프트·쿼리 재작성 6브랜치 + 픽셀 다수결 + 일관성 가중 융합

Yun et al., "StAR: Segment Anything Reasoner," arXiv:2603.14382, 2026.

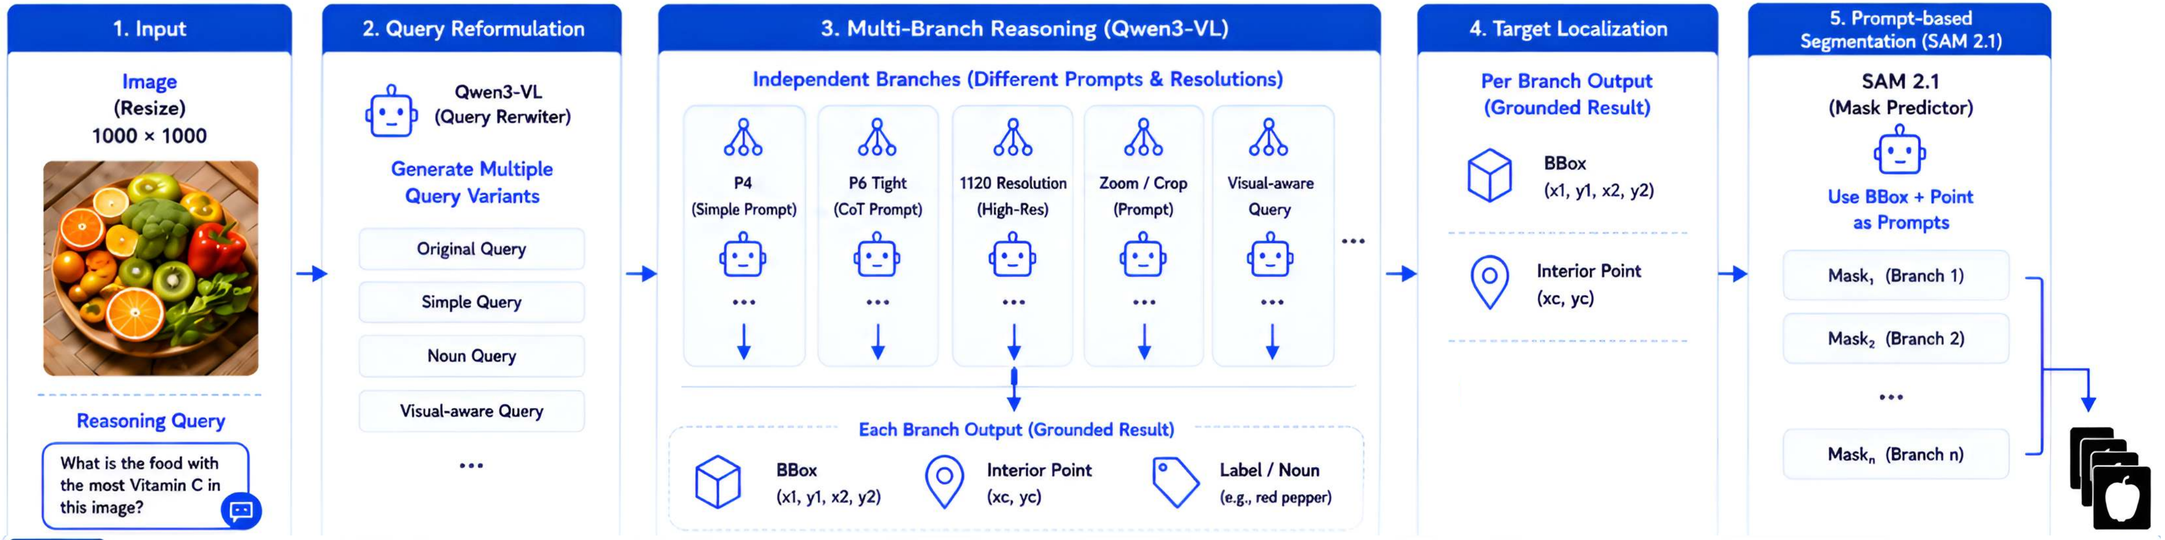
The person who is in the lead right now.

The person who is in the

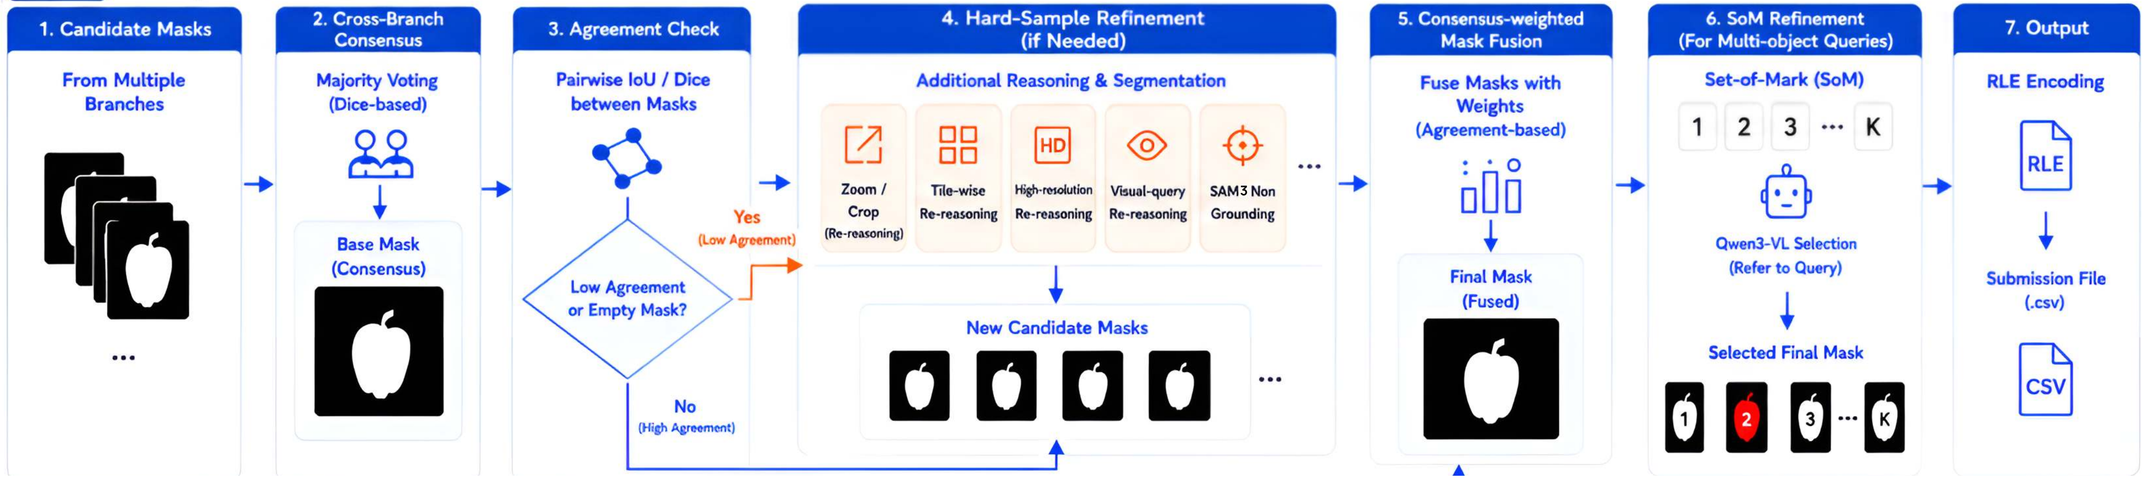
Pipeline

Reasoning → Grounding → Segmentation

1/2 Multi-Branch Reasoning & Initial Segmentation

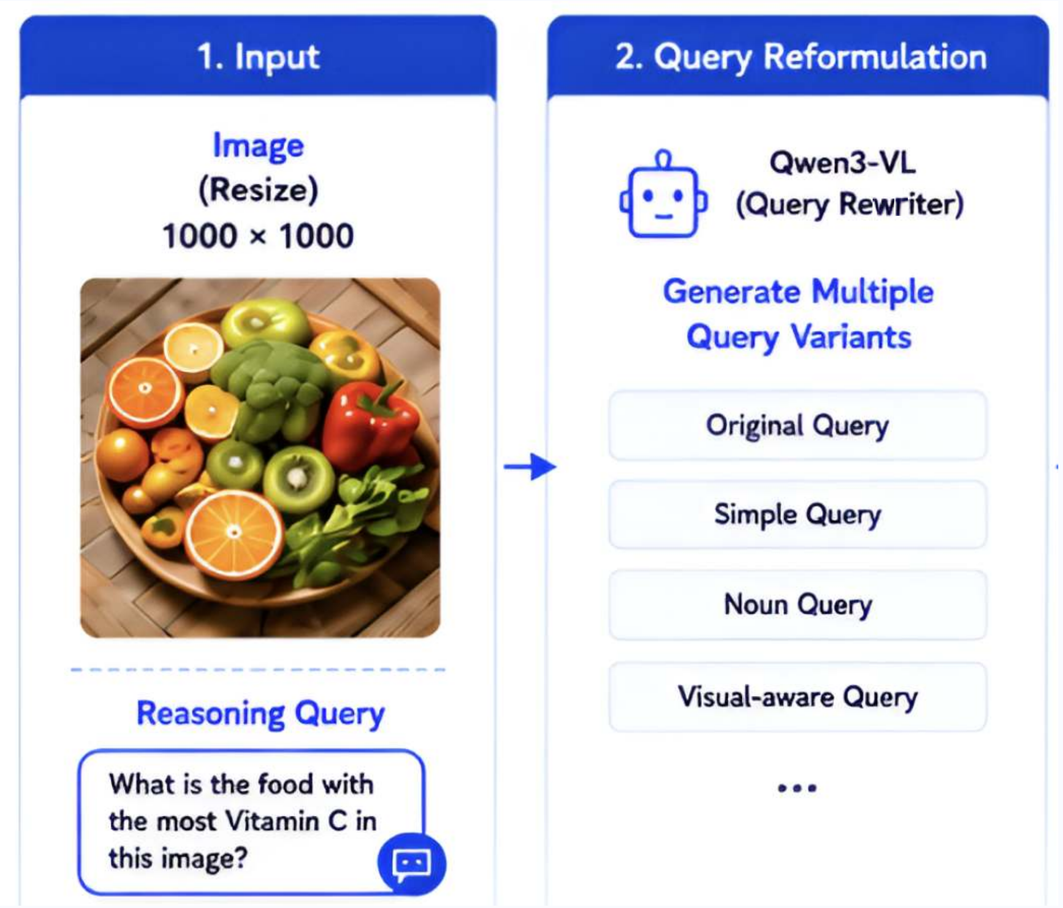


2/2 Adaptive Refinement & Consensus Fusion



Pipeline | Multimodal Input & Query Diversification

동일 Query를 서로 다른 방식으로 표현하여 해석 편향을 완화함



Original Query

원문 그대로

Simple Query

직접적 표현 (ONE direct, literal English sentence)

Noun Query

간결하게 표현 (1-6 words)

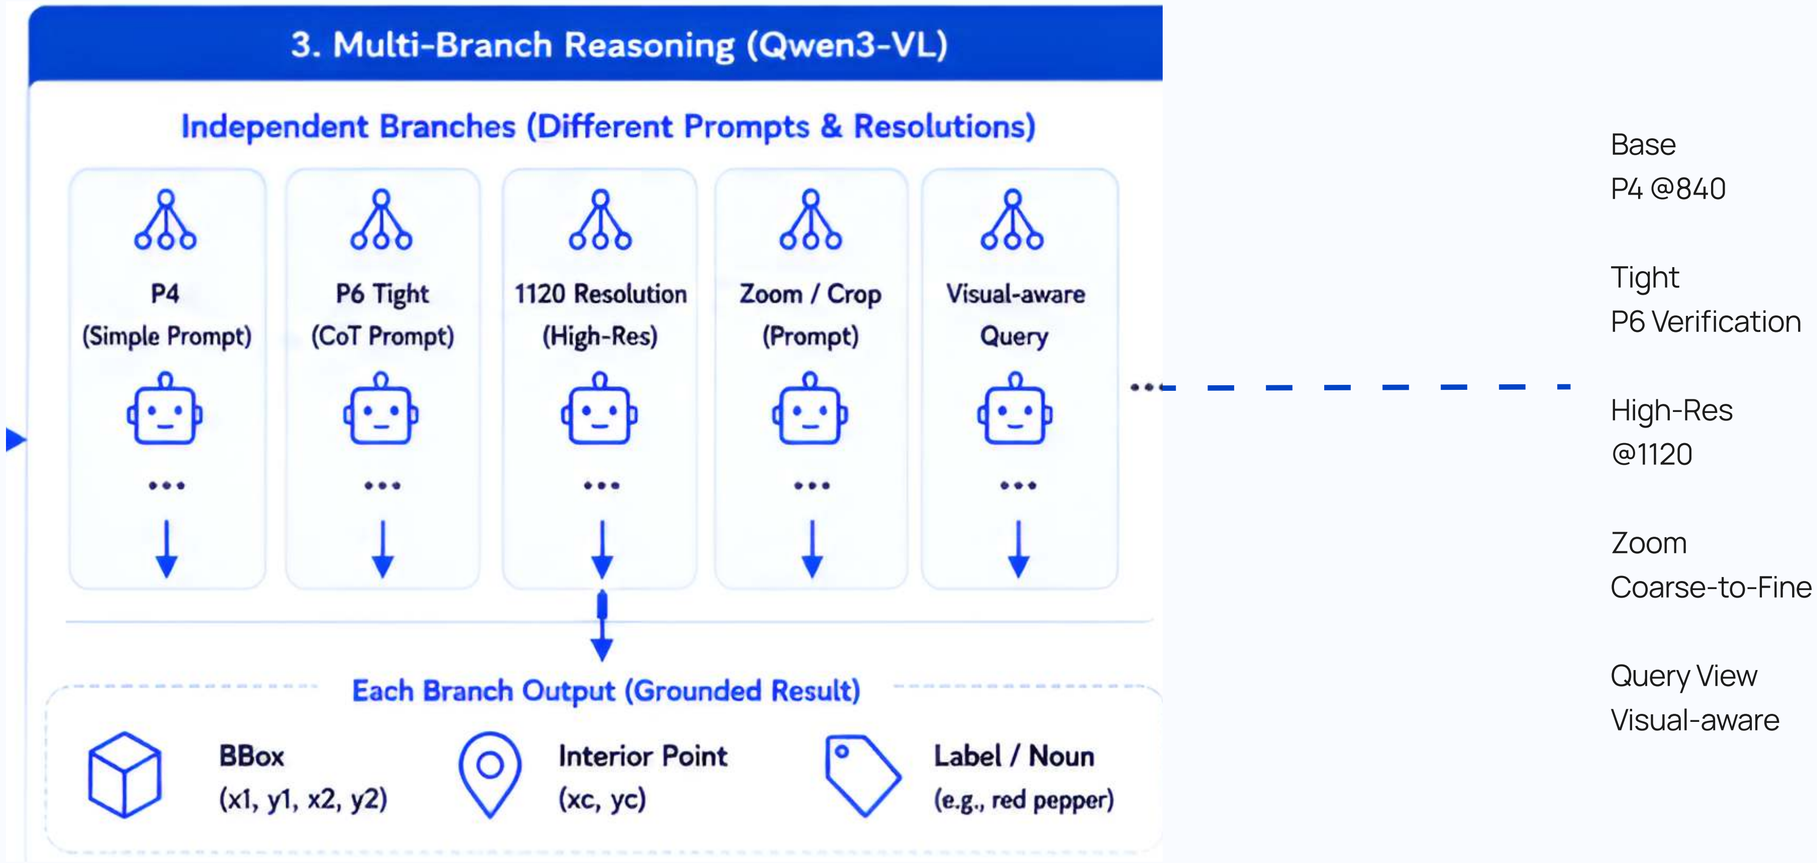
Visual-aware Query

보이는 대상 중심 (names the actual visible object)

Deng et al., "Rephrase and Respond: Let Large Language Models Ask Better Questions for Themselves,"

Pipeline I Multi-Branch Visual Grounding

Qwen3-VL은 바로 mask를 생성하는게 아니라, 대상이 무엇인지 추론한 다음 그 대상의 bbox + 내부 point를 출력함

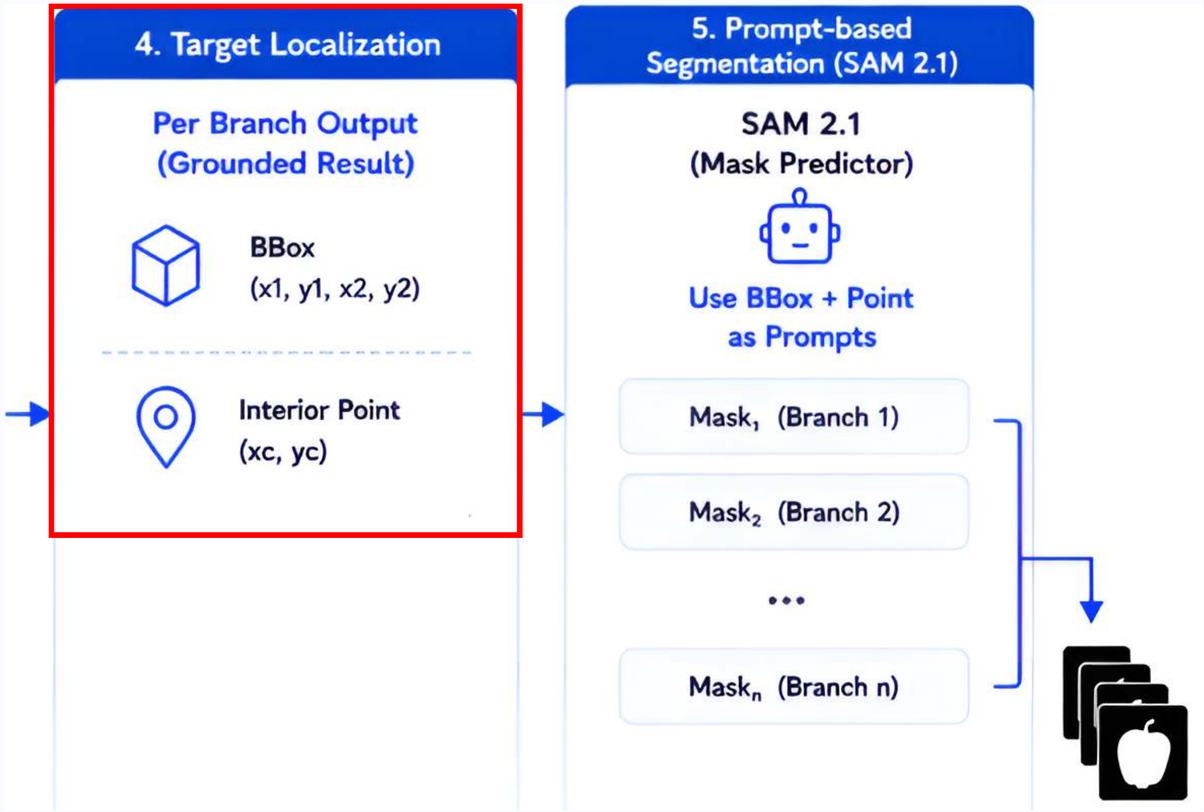


→ Prompt · Resolution · Spatial View를 다양화하여 상호보완적 Grounding 생성

[1] Wang et al., "Self-Consistency Improves Chain of Thought Reasoning in Language Models," ICLR 2023. (arXiv:2203.11171)

Pipeline I Grounding Representation

Qwen3-VL(Semantic Reasoning) → Spatial Cues

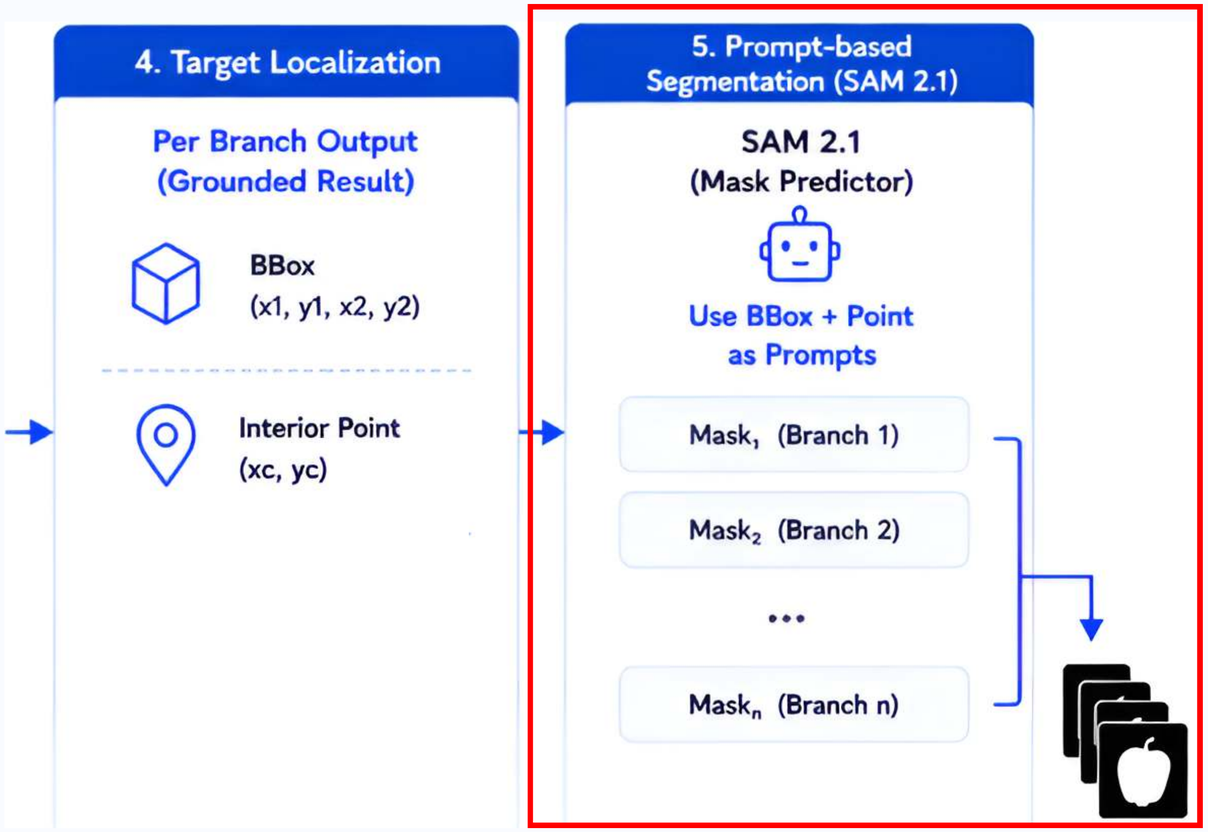



```
{
 "bbox_2d": [x1, y1, x2, y2],
 "point_2d": [x, y]
}
```

→ SAM2 predictor 호출시
두 가지 spatial prompt를 동시에 줄 수 있음

Pipeline I SAM2.1 Segmentation

Prompt-based Segmentation - SAM2.1 Pixel-level Refinement

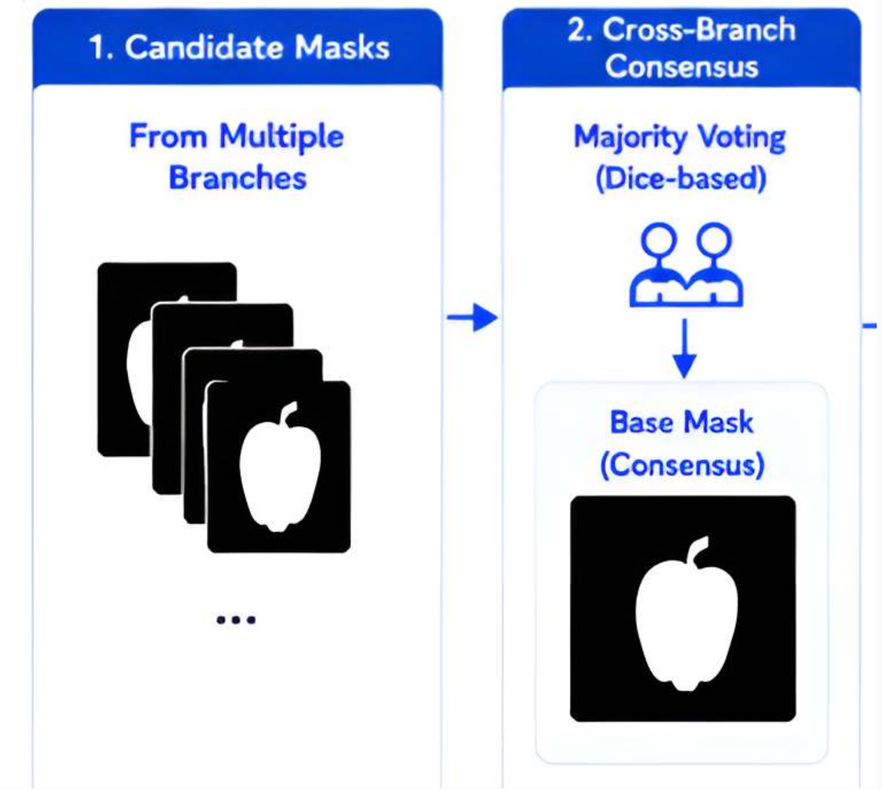



```
predictor.predict(
    point_coords=[pt],
    point_labels=[1],
    box=np.array(b)
)
```

→ SAM2는 Branch 하나 당 하나의 마스크를 출력
(One Branch → One Candidate Mask)

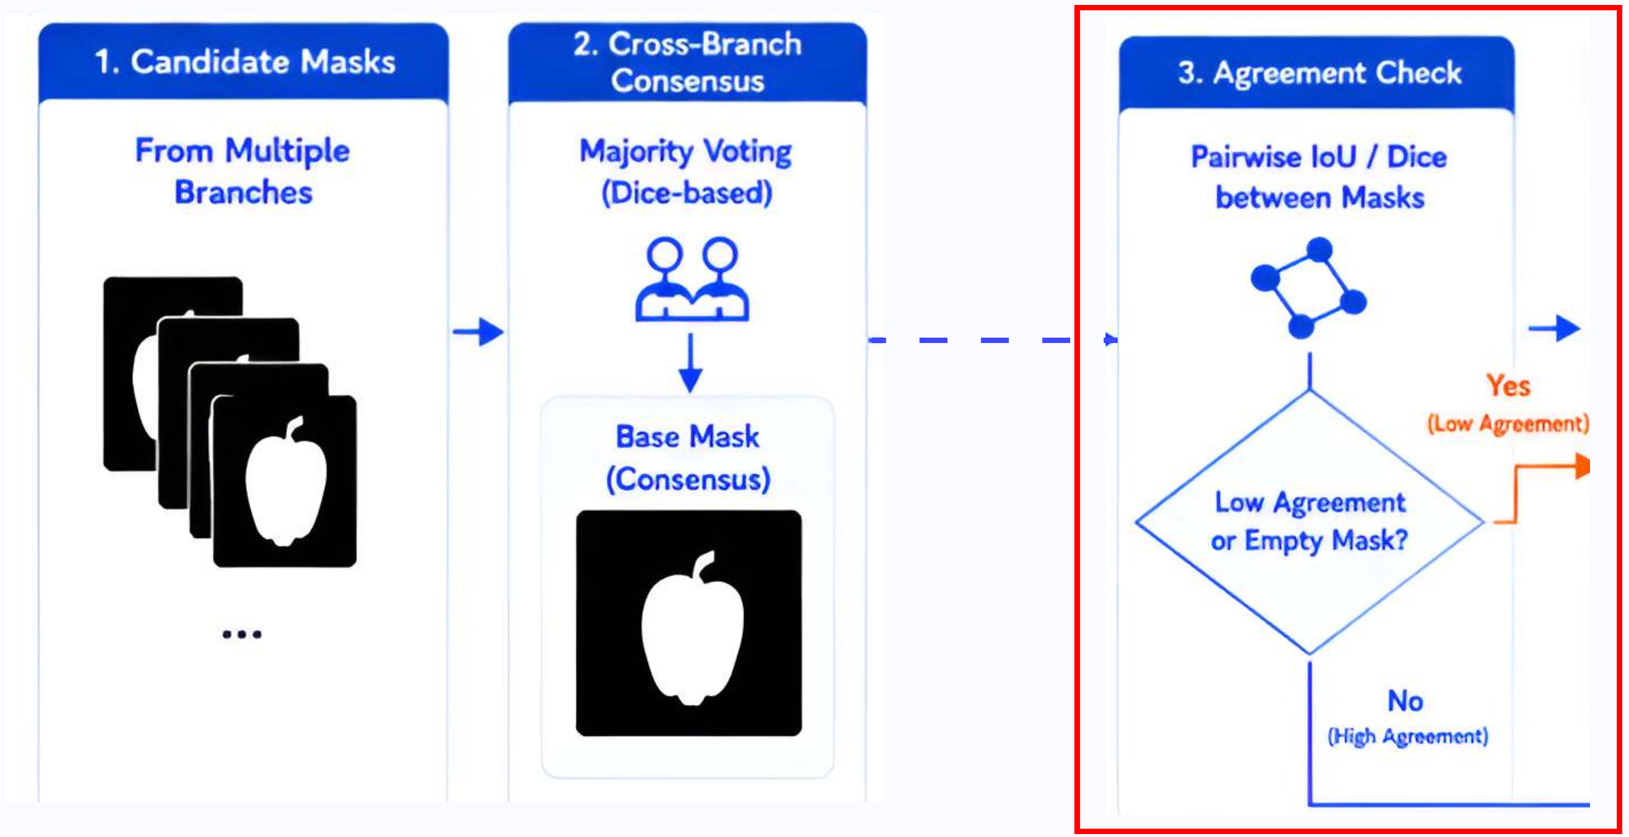
💡 Qwen3-VL은 '무엇을 찾을지'를 추론하고, SAM2.1은 '어디까지인지'를 정밀하게 분할

Pipeline | Cross-Branch Consensus



여러 Grounding 경로의 공통 영역을 초기 Mask로 채택

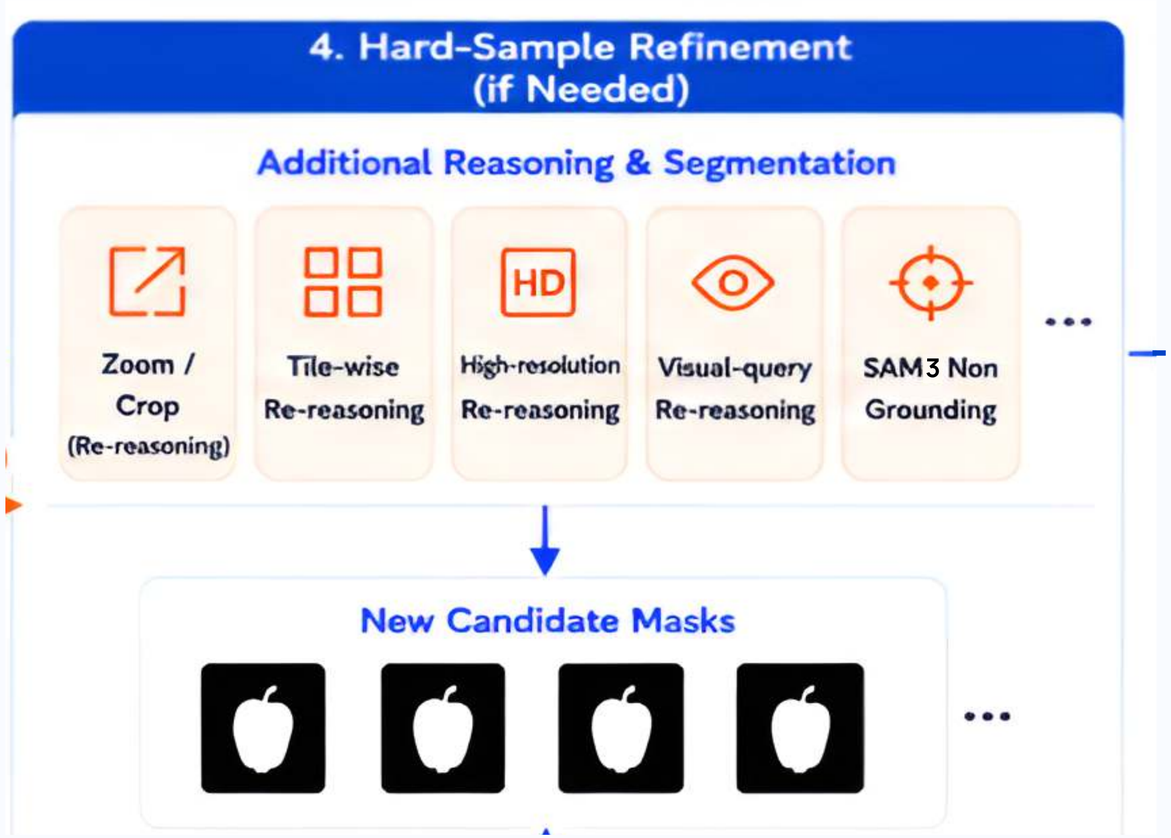
Pipeline | Difficulty Detection



Pairwise IoU / Dice between Branch Masks

서로 다른 branch가 서로 다른 영역을 예측한다는 사실을 난이도 신호로 활용

Pipeline | Adaptive Hard-Sample Refinement



Zoom / Crop
Coarse-to-Fine

Tile
Local Views

High-Resolution
Fine-detail View

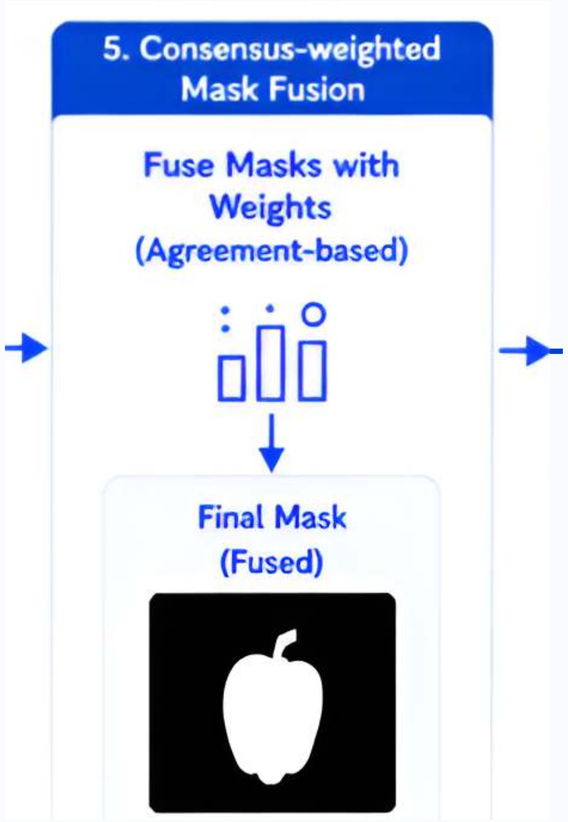
Visual Query
Alternative Semantic View

SAM3
Independent Segmentation

불확실한 샘플에만 추가적인 공간·해상도·모델 관점 투입

[1] Wu & Xie, "V*: Guided Visual Search as a Core Mechanism in Multimodal LLMs," CVPR 2024. (arXiv:2312.14135)

Pipeline | Consensus-Weighted Fusion



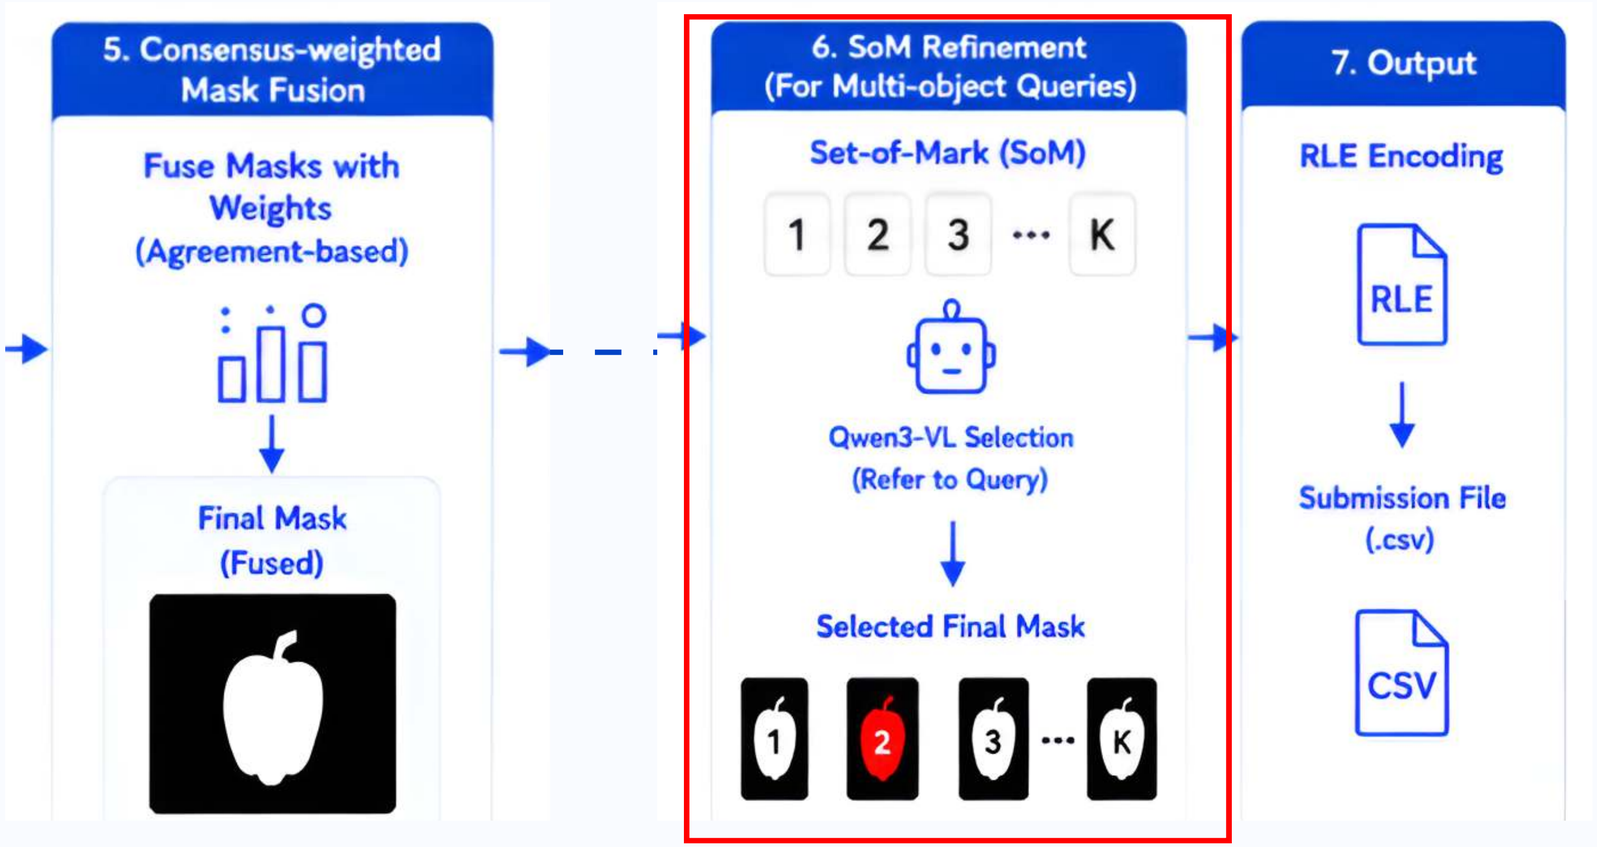
$$w_i = \frac{1}{N-1} \sum_{j \neq i} Dice(M_i, M_j)$$

$$M_{\text{final}} = 1 \left[\sum_i w_i M_i \geq 0.5 \sum_i w_i \right]$$

Mask A ✓✓✓ → High Weight
Mask B ✓✓ → Medium Weight
Mask C ✗✗✗ → Low Weight

다른 예측과 높은 일관성을 보이는 Mask에 더 큰 가중치 부여

Pipeline | Set-of-Mark Region Selection



SAM Candidates

1 2 3 ... K

↓

Qwen3-VL

"Which regions satisfy the query?"

↓

2, 5, 7

↓

Union Mask

Pixel Generation → Candidate Selection, 복수 객체 Query에서 단일 객체 편향 보완

Pipeline | Set-of-Mark Region Selection

그래서 정리하자면...

	Image + Query
질문 의도 파악, 표현 정리	Query 이해 / 재작성
대상이 대충 어디 있지?	Qwen3-VL Grounding
그 물체의 정확한 픽셀 영역은?	SAM2.1
Easy / Hard sample 분석	여러 추론 Branch 비교
Tile High-res SoM SAM3	Hard sample만 추가 추론
	Mask Ensemble
	RLE Encoding
	Submission

bbox + point

mask

"Which regions satisfy the query?"

Pixel Generation → Candidate Selection, 복수 객체 Query에서 단일 객체 편향 보완

Trial and Error

0.51026 → 0.53782 → 0.54202 → 0.55873 → 0.56205

출발점 · 결합 방식 선택 · 투표자 질 개선 · 최대 개선 · 최종 결과

0 출발점

학습 금지 → Test-time 활용

LoRA 사용 불가로 base Qwen3-VL-8B + SAM2.1 재구성

프롬프트 · TTA · 쿼리 재작성 · 앙상블 중심으로 설계

→ P4를 기본 프롬프트로 확정

1 결합 방식 선택

많이 찾기 vs 정확히 찾기

합집합 0.51026 < 다수결 0.53782

정량만 꺼내면 재현하고,
놓친 것은 풀백으로 구제

→ Majority Voting 방향 확정

2 투표자 질 개선

flip → P6 교체

자기검증 프롬프트 P6 도입

0.53782 → 0.54202 (+0.42pt)

→ 브랜치 수보다 브랜치 질이 중요

3 최대 개선

Difficulty Routing

쉬운 145개는 유지,
어려운 55개만 추가 개선

좀 · 타일 · 1344px · SAM3를
일관성 가장 좋음

→ 0.54202 → 0.55873 (+1.67pt)

4 진단 실험

3개 모두 기각

- tailrefine: 경계보다 위치 선정이 문제
- draw-and-verify: 자기교정 신뢰 불가
- liselect: 로짓 재정도 배포 규문에서 실패

→ 신뢰 가능한 무감독 신호는
브랜치 간 합의

5 마지막 한 수

SoM Patch

복수 인스턴스 쿼리에서
번호 선택 방식 도입

D key 1개 → 6개 복원, +0.3?2pt

→ 최종 0.56205, LB 1위

학습 없이도, 결합 방식 → 브랜치 질 → 난이도 라우팅 → 실패 유형 정밀 타격 순으로 좁혀 들어가 0.510 → 0.562을 달성

Thank You

Q & A